Technique et chaîne de publication électronique avec XSLT

Jean-Damien Généro

2025, 1er dec. - 2026, 20 janv.

École nationale des chartes – M2 TNAH

Contact

- jean-damien.genero@cnrs.fr

Objectifs

- XPath
  - Naviguer dans un arbre XML
  - Manipuler les principales fonctions XPath
- XSLT
  - Manipuler les règles (*templates*) basiques
  - Manipuler les conditions et les boucles
- Édition numérique
  - Transformer un document XML en un autre document XML
  - Transformer un document XML en un document HTML
  - Transformer un document XML en un document LaTeX
  - Coder une chaîne de publication électronique utilisant XSLT avec Python

Écosystème XML

- XML $\rightarrow$ *langage de balisage qui encode une description de la mise en page et de la structure logique d'un document*
  - XPath $\rightarrow$ *langage de requête pour naviguer dans la structure hiérarchique d'un document XML à l'aide de chemins*;
- XSL $\rightarrow$ *spécifications pour écrire des feuilles de style (stylesheet)*;
- XSLT $\rightarrow$ *un langage conçu pour transformer des documents XML en d'autres documents selon les spécifications XSL.*

W3C Recommendations : XML, XPath, XSL, XSLT.

Écosystème XML/ Schéma

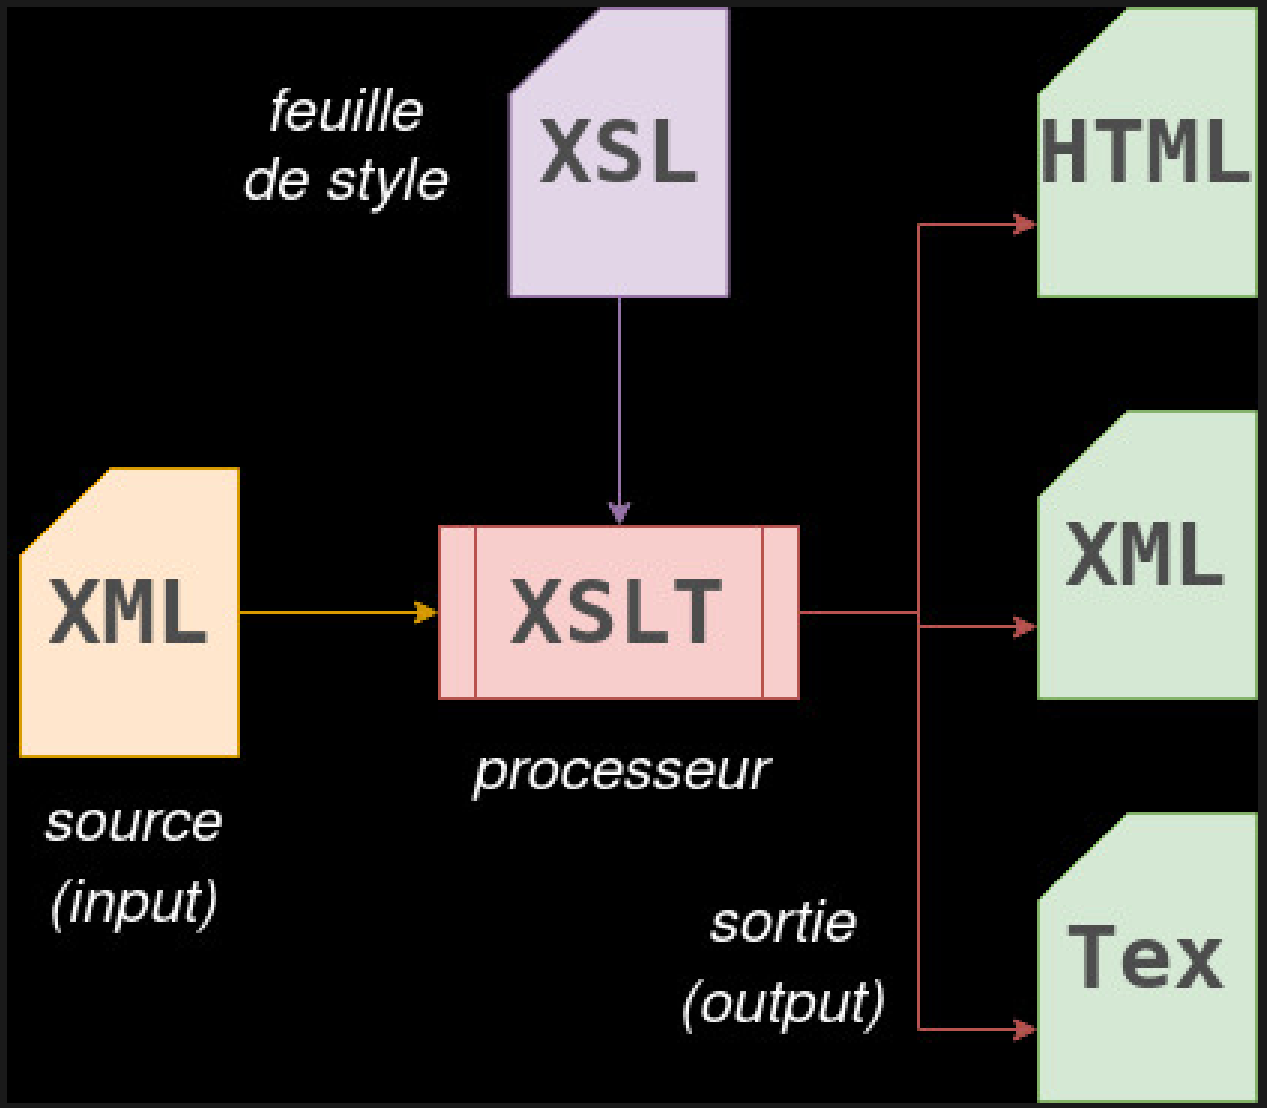

- Navigation XPath :
  - Doc XML = structuré, on parle d'« **arbre** » (*XML tree*) ;
  - **Itinéraire** vers une balise (« **parent** » $\rightarrow$ « **enfant** ») ;
  - Rédaction dans une **syntaxe propre**.
- Règle XSL (*template*) :
  - **Agir** sur une ou plusieurs balises (*transform*) ;
  - Exemples : **copier** balise + contenu, copier uniquement le contenu et l'**insérer** dans une nouvelle balise, **ajouter** ou **supprimer** un attribut, etc. ;
  - Rédaction dans une **syntaxe XML** (langage à balises).
- Utilisation avec d'autres langages
  - *Python* : librairie `lxml`.

Écosystème XML/ Exemple d'un chemin XPath dans un *XML tree*

- Comment accéder aux balises *<p>* avec XPath ?

```
<TEI>
    <teiHeader/>
    <text>
        <body>
            <div>
                <p>title</p>
                <p>text</p>
            </div>
        </body>
    </text>
</TEI>
```

- *<TEI>* → *<text>* → *<body>* → * * → *<p>*
- Traduction XPath : */TEI/text/body/div/p*
- Simplification : *//body/div/p* (/~~TEI/text~~/body/div/p)

Écosystème XML/ Exemple d'une règle XSL

- Comment appliquer une règle XSL aux balises *<p>*?
  - Une règle XSL est toujours contenue dans une balise *<xsl:template/>* possédant un *@match*.
- Indiquer le chemin XPath vers les *<p>* dans l'*@match*.

```
<xsl:template match="/TEI/text/body/p">
    <xsl:copy-of select="."/>
</xsl:template>
```

ou

```
<xsl:template match="//body/p">
    <xsl:copy-of select="."/>
</xsl:template>
```

XPath

- **Nœud** (*node*) (7) = composant de l'arbre : *root*, *element*, *attribute*, *text*, *comment*, *namespace* et *processing instruction*.
- Deux rôles : ***current node*** (fixe, le premier du chemin) ou ***context node*** (variable, celui que XPath évalue à l'instant *t*);
- Écrire un chemin (*expression*) : succession de nœuds séparés par l'**opérateur /** ;
  - Tester dans Oxygen :
    `/TEI/text/body/div/p`

- Un axe permet de qualifier la **relation** entre le **nœud de contexte** et un ou des **autre(s) nœud(s)**.
- Direction basique : **parent** $\rightarrow$ **enfant**.
- 13 axes XPath, dont :
  - *`parent::`* $\rightarrow$ nœud immédiatement au-dessus ;
  - *`child::`* $\rightarrow$ nœud immédiatement en-dessous ;
  - *`following-sibling::`* $\rightarrow$ nœud(s) après celui de contexte et qui ne fait/font pas partie de ses descendants ;
  - *`ancestor`*, *`descendant`*, *`preceding`*, etc.

XPath/ Axe `ancestor::`

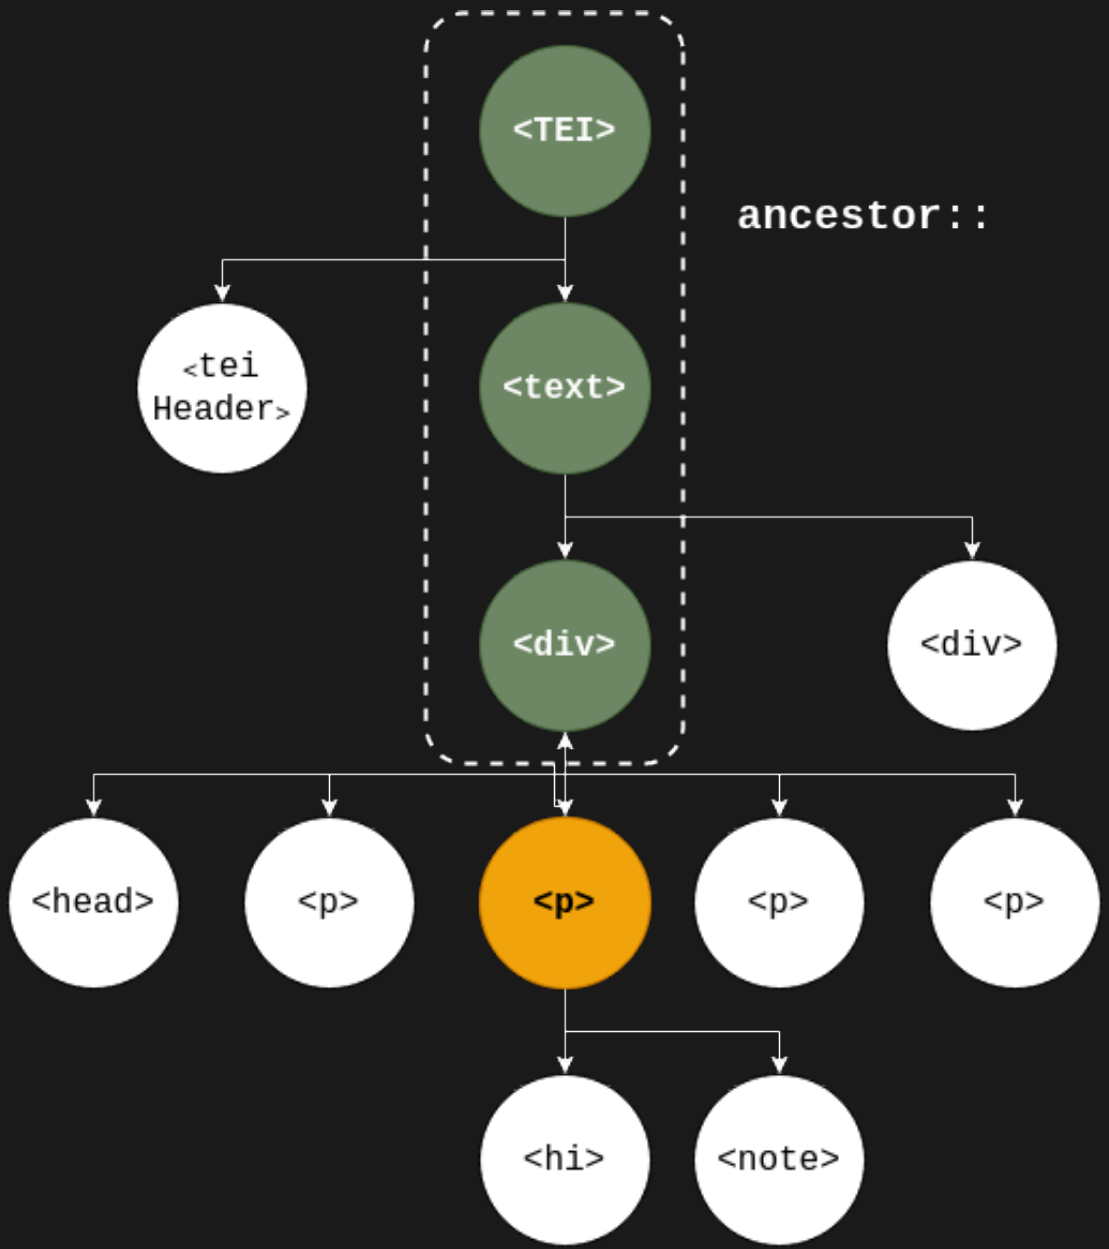

XPath/ Axe `child::`

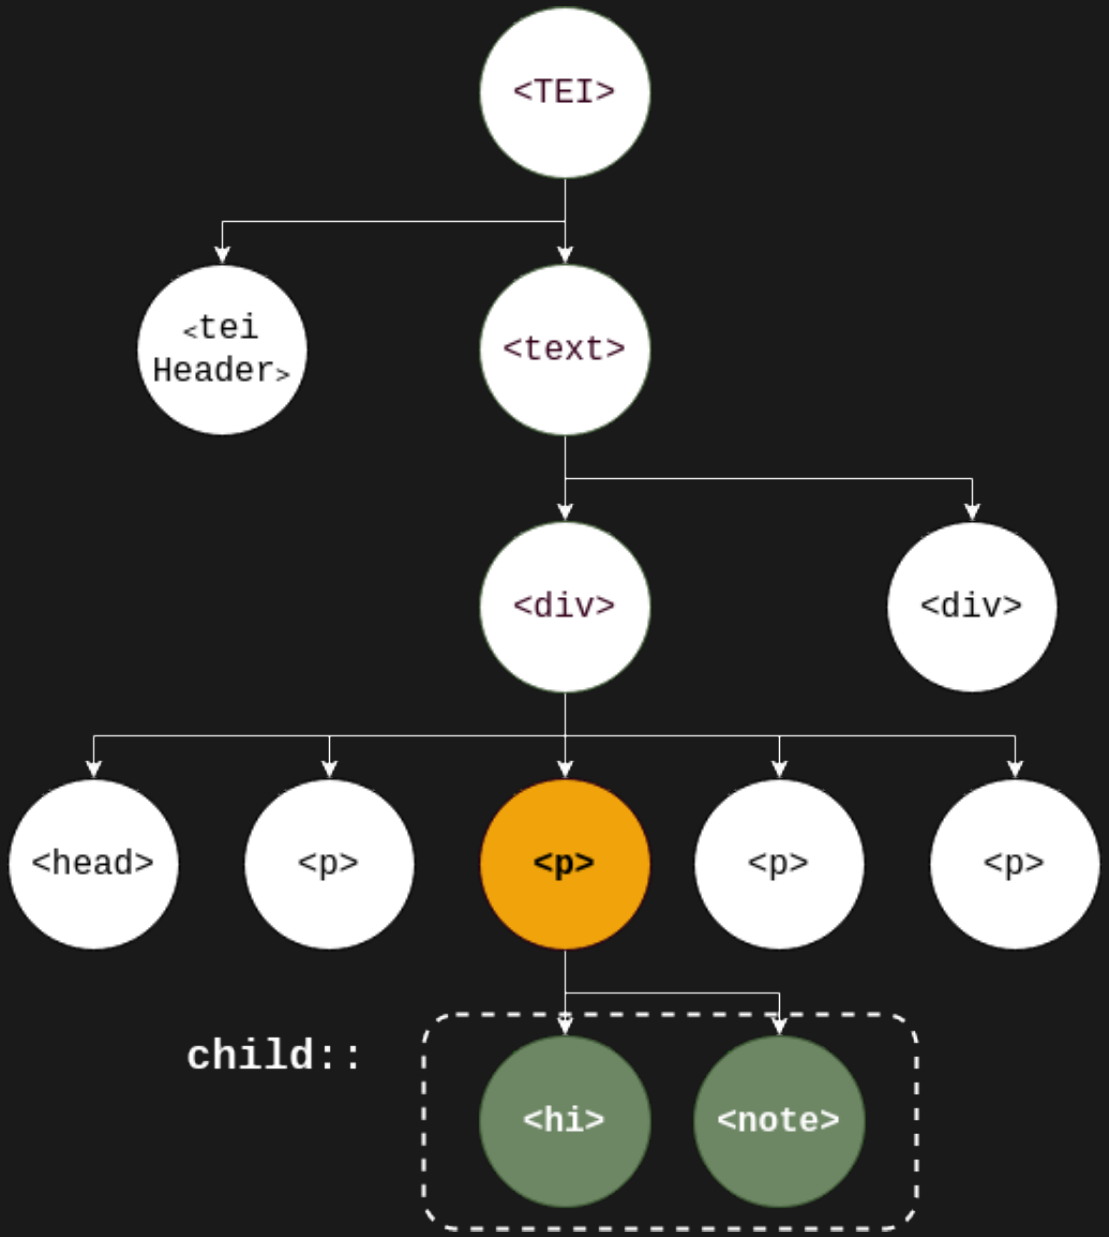

XPath/ Axe following-sibling::

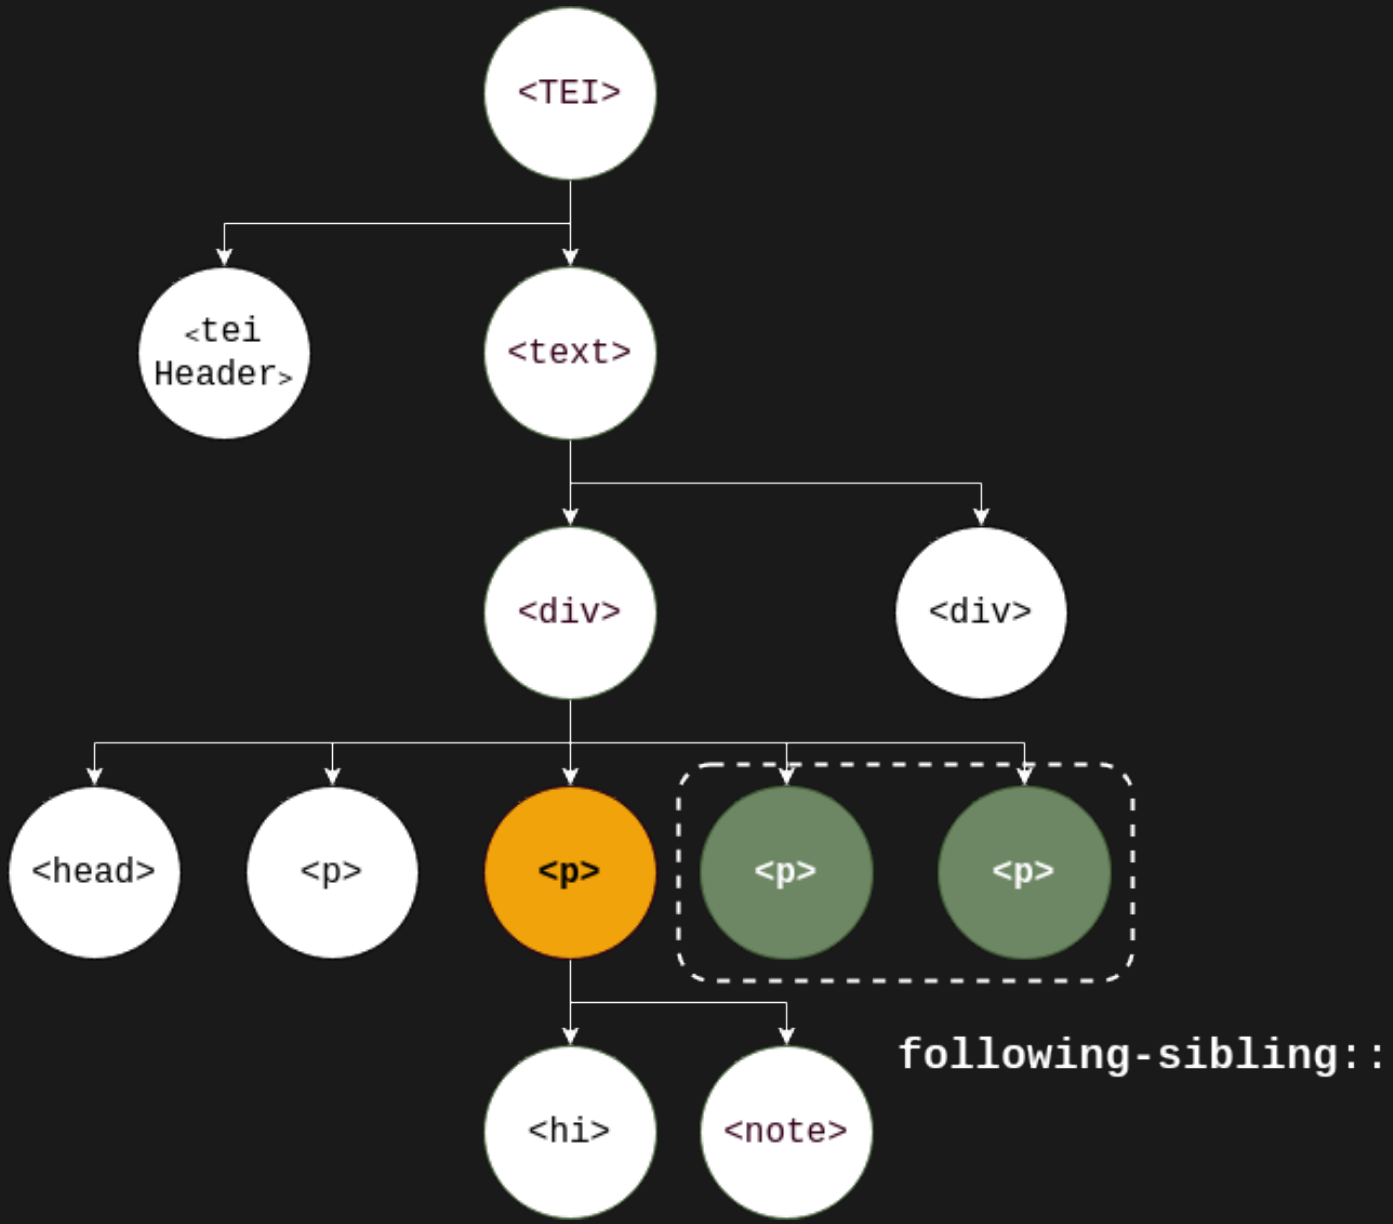

XPath/ Abbréviations des axes

- 1er élément de l'arbre (*root node*) → `/` (*attention : différent de la racine* `<TEI>`)
- `decendant-or-self::` → `//`
- `self::` → `.`
- `attribute::` → `@`

- Donc : vous pouvez écrire `//div/@n` au lieu de `//div/attribute::n`.

Prédicats : définition

- Prédicat (filtre) = **condition** qui doit être satisfaite par le nœud de contexte (existence d'un attribut, valeur d'un attribut, position d'une balise, etc.).
- Écrit entre crochets *[ ]*.

- *//div[@n='2']/head* = le *<head>* de la * * avec un *@n* de valeur *2*.

- *//body/div[@n='2']/p[2]* = *?*

- *//tag[position()=2]* ou *//tag[2]* → condition de position (*<tag>* n°2);
- *//tag[last()]* → dernier *<tag>*;
- *//tag[@foo='bar']* → expression logique (*<tag>* avec un *@foo* dont la valeur est *bar*);

- Arbre XML, racine, nœuds (7, notés avec *( )*);
- Chemin XPath, opérateur */* ;
- Axes de relation (13, notés avec *::*);
- Prédicats (notés avec *[ ]*).

 Exercice. *Journal de Jean Le Fèvre*.

- Donner le chemin de la racine vers `<msName>` dans le `<sourceDesc>`.
- Utiliser un prédicat pour sélectionner le `<idno>` avec le `@source="gallica"`.

XSLT : élément racine et instructions de premier niveau

XSLT/ Définition

- XSLT $\rightarrow$ un **langage de programmation**;
- Permet de **transformer un doc XML** en un autre doc (*.xml*, *.html*, *.tex*, etc.);
- Transformation opérée par un **processeur XSLT**
  - **Construit** l'arbre output, **transforme** l'arbre input et **sérialise** le document output;
  - Le plus connu $\rightarrow$ **Saxon** (en ligne de commande);
  - Généralement **intégré** à des logiciels (**Oxygen**) ou des librairies (**python : lxml**).

- Feuille de style XSL == un doc XML `.xsl` ;
- Contient des instructions ou règles (*templates*) ;
- Élément racine : `<xsl:stylesheet>`

- Dans Oxygen → ouvrir un nouveau doc « XSLT Stylesheet ».
- Observer les attributs de l'élément racine.

Élément racine : `<xsl:stylesheet>` (1/4)

Espaces de nom (*namespace*) et attributs présents de base dans Oxygen :

- *`@xmlns:xsl`* : espace de nom XSL;
- *`@xmlns:xs`* : espace de nom XML;
- *`@xmlns:math`* : espace de nom math (XPath 3);
- *`@exclude-result-prefixes`* : liste des préfixes qui ne seront pas copiés dans l'output;
- *`@version`* : version de XSL (1, 2 ou 3).

 Élément racine : `<xsl:stylesheet>` (2/4)

Attributs à remplacer dans Oxygen *pour une transformation vers XML-TEI* :

- remplacer *`@xmlns:xs`* par *`@xmlns:tei`* → espace de noms de l'élément racine de l'output.
  - évite l'ajout de *`tei:`* à chaque élément "matché" par une règle (*`@match`*).

- remplacer *`xs`* par *`tei`* dans *`@exclude-result-prefixes`*.

 Élément racine : `<xsl:stylesheet>` (3/4)

Attributs à ajouter dans Oxygen *pour une transformation vers XML-TEI* :

- *`@xpath-default-namespace`* : espace de noms des chemins XPath de la feuille de style (http ://www.tei-c.org/ns/1.0).
  - évite de devoir écrire le préfixe *`tei:`* devant chaque nœud d'une expression XPath.
- *`@xmlns`* avec l'adresse de l'espace de noms TEI.
  - détermine l'espace de noms de l'ensemble du document de sortie.

Élément racine : `<xsl:stylesheet>` (4/4)

- **attention** : TEI est un standard XML parmi d'autres ! Pour EAD, changer l'espace de noms TEI par celui d'EAD et le préfixe *`tei:`* par *`ead:`*.
- Atributs pour la transformation vers HTML ou LaTeX :
  - *`@xmlns:xsl`* (adresse de l'espace de noms XSLT)
  - *`@xpath-default-namespace`* (adresse de l'espace de noms TEI)
  - *`@version`* (version de XSL utilisée)

XSLT/ Instruction de 1er niveau : `<xsl:output>`

- Instruction de premier niveau ;
- « contrôle les caractéristiques du document de sortie ».

```
<xsl:output
    method="xml | html | text"
    indent="yes | no"
    omit-xml-declaration="yes | no"
    encoding="UTF-8"
/>
```

XSLT/ Écriture d'une règle : `<xsl:template>` (1/4)

- une règle peut être écrite de plusieurs manières;
- *`<xsl:template>`* → définir une règle;
- Possède un *`@match`* avec pour valeur un chemin XPath qui donne l'emplacement du nœud sur lequel sera appliquée la règle.
- Un doc peut être composé d'une seule règle ou d'une succession de règle. Important → **cohérence des XPath**.

 Écriture d'une règle : `<xsl:template>` (2/4)

- 1. Appliquer une règle vide sur la racine :

```
<xsl:template match="/">
</xsl:template>
```

- 2. Appliquer la règle *copy-of* sur la racine :

```
<xsl:template match="/">
    <xsl:copy-of select="."/>
</xsl:template>
```

Écriture d'une règle : `<xsl:template>` (3/4)

- Effet d'une règle vide $\rightarrow$ la partie de l'arbre d'entrée sélectionnée n'est pas copiée dans l'arbre de sortie.
- Effet de *`<xsl:copy-of/>`* $\rightarrow$ copie à l'identique la balise matchée par le @select et ses nœuds enfants ;
- **Comment copier le `<text>` dans l'output, mais sans le `<teiHeader>` ?**

 Écriture d'une règle : `<xsl:template>` (4/4)

- Comment obtenir cet arbre en output ?

```
<div>
    <head>Extrait du Journal de
          Jean Le Fèvre</head>
    <div n="1">
        <!-- copie de la div n°1 de l'input -->
    </div>
    <div n="2">
        <!-- copie de la div n°2 de l'input -->
    </div>
</div>
```

XSLT : première approche. Notions essentielles

- Transformation et feuille de style XSL ;
- Manipulation de XSL avec Oxygen ;
- Élément racine : *<xsl:stylesheet>* et ses attributs (en-tête XSL) ;
- Instructions de premier niveau :
  - *<xsl:output>* ;
  - *<xsl:template>* et son *@match*.