Technique et chaîne de publication électronique avec XSLT

Jean-Damien Généro

2023, 9 janv. - 13 fev.

École nationale des chartes – M2 TNAH

Contact

- jean-damien.genero@cnrs.fr

Objectifs

- XPath
  - Naviguer dans un arbre XML
  - Manipuler les principales fonctions XPath
- XSLT
  - Manipuler les règles (*templates*) basiques
  - Manipuler les conditions et les boucles
- Édition numérique
  - Transformer un document XML en un autre document XML
  - Transformer un document XML en un document HTML
  - Transformer un document XML en un document LaTeX

Écosystème XML

Écosystème XML/ Principes généraux

- XML $\rightarrow$ *a markup language that encodes a description of a doc's storage layout and logical structure*;
  - XPath $\rightarrow$ *use a path notation for navigating through the hierarchical structure of an XML doc*;
- XSL $\rightarrow$ *a language for expressing stylesheets*;
  - *stylesheet $\rightarrow$ express intentions about how a structured content [i. e. XML doc] should be presented*;
- XSLT $\rightarrow$ *a language designed for transforming XML documents into other XML documents.*

W3C Recommendations : XML, XPath, XSL, XSLT

Écosystème XML/ Schéma

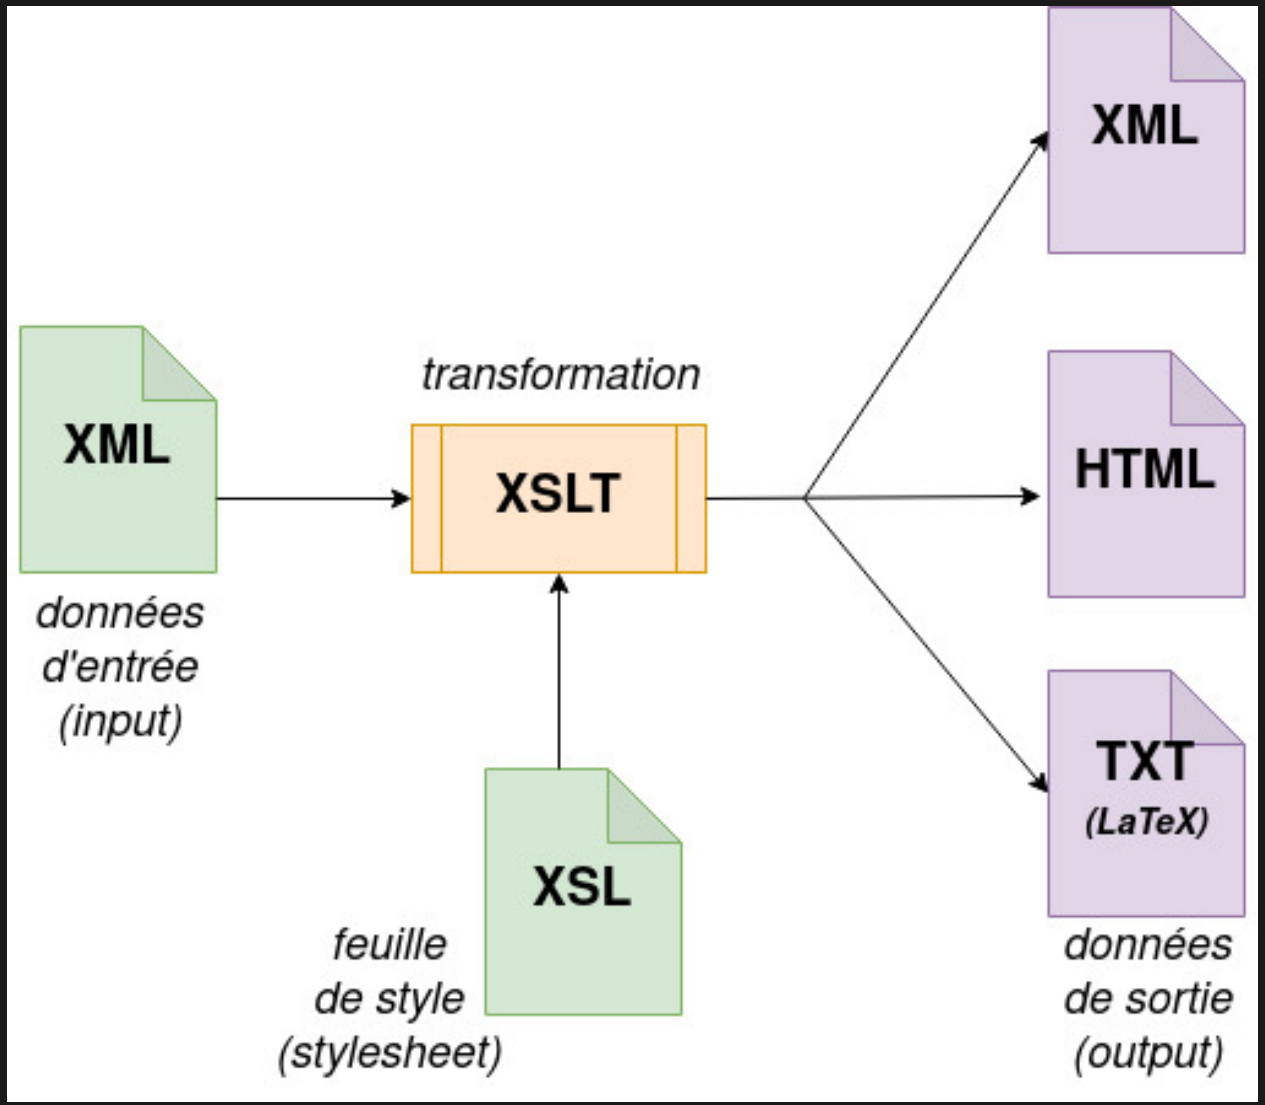

- Navigation XPath :
  - Doc XML = structuré, on parle d'« **arbre** » (*XML tree*) ;
  - **Itinéraire** vers une balise (« **parent** » $\rightarrow$ « **enfant** ») ;
  - Rédaction dans une **syntaxe propre**.
- Règle XSL (*template*) :
  - **Agir** sur une ou plusieurs balises (*transform*) ;
  - Exemples : **copier** balise + contenu, copier uniquement le contenu et l'**insérer** dans une nouvelle balise, **ajouter** ou **supprimer** un attribut, etc. ;
  - Rédaction dans une **syntaxe XML** (langage à balises).
- Utilisation avec d'autres langages (*Python* : `lxml`).

Écosystème XML/ Exemple d'un chemin XPath

- Comment accéder aux balises *<p>* avec XPath ?

```
<TEI>
    <teiHeader/>
    <text>
        <body>
            <p>title</p>
            <p>text</p>
        </body>
    </text>
</TEI>
```

- *<TEI>* $\rightarrow$ *<text>* $\rightarrow$ *<body>* $\rightarrow$ *<p>*
- Traduction XPath : */TEI/text/body/p*
    - Simplification : *//body/p* (*/~~TEI/text~~/body/p*)

Écosystème XML/ Exemple d'une règle XSL

- Comment appliquer une règle XSL aux balises *<p>*?
  - Une règle XSL est toujours contenue dans une balise *<xsl:template/>* possédant un *@match*.
- Indiquer le chemin XPath vers les *<p>* dans l'*@match*.

```
<xsl:template match="/TEI/text/body/p">
    <xsl:copy-of select="."/>
</xsl:template>
```

ou

```
<xsl:template match="//body/p">
    <xsl:copy-of select="."/>
</xsl:template>
```

XPath

- **Nœud** (*node*) = un composant de l'arbre XML. Sept types, dont : **balise**, **attribut**, ***text***, *namespace*.
- Écrire un chemin (*expression*) : succession de nœuds séparés par l'**opérateur /** ;
  - `/TEI/text/body/p`
- Axe (direction) basique : **parent** → **enfant**

 Exercice n°1. *Saint Julien l'hospitalier*, II.

- Donner le chemin de la racine vers le premier paragraphe.
- Donner le chemin de la racine vers `<author>` dans le `<sourceDesc>`.

- Un axe permet de qualifier la **relation** entre le **nœud de contexte** et un ou des **autre(s) nœud(s)**.
- 13 axes XPath, dont :
  - *`parent::`* → nœud immédiatement au-dessus ;
  - *`child::`* → nœud immédiatement en-dessous ;
  - *`following-sibling::`* → nœud(s) après celui de contexte et qui ne fait/font pas partie de ses descendants ;
  - *`ancestor`*, *`descendant`*, *`preceding`*, etc.

XPath/ Axe `ancestor::`

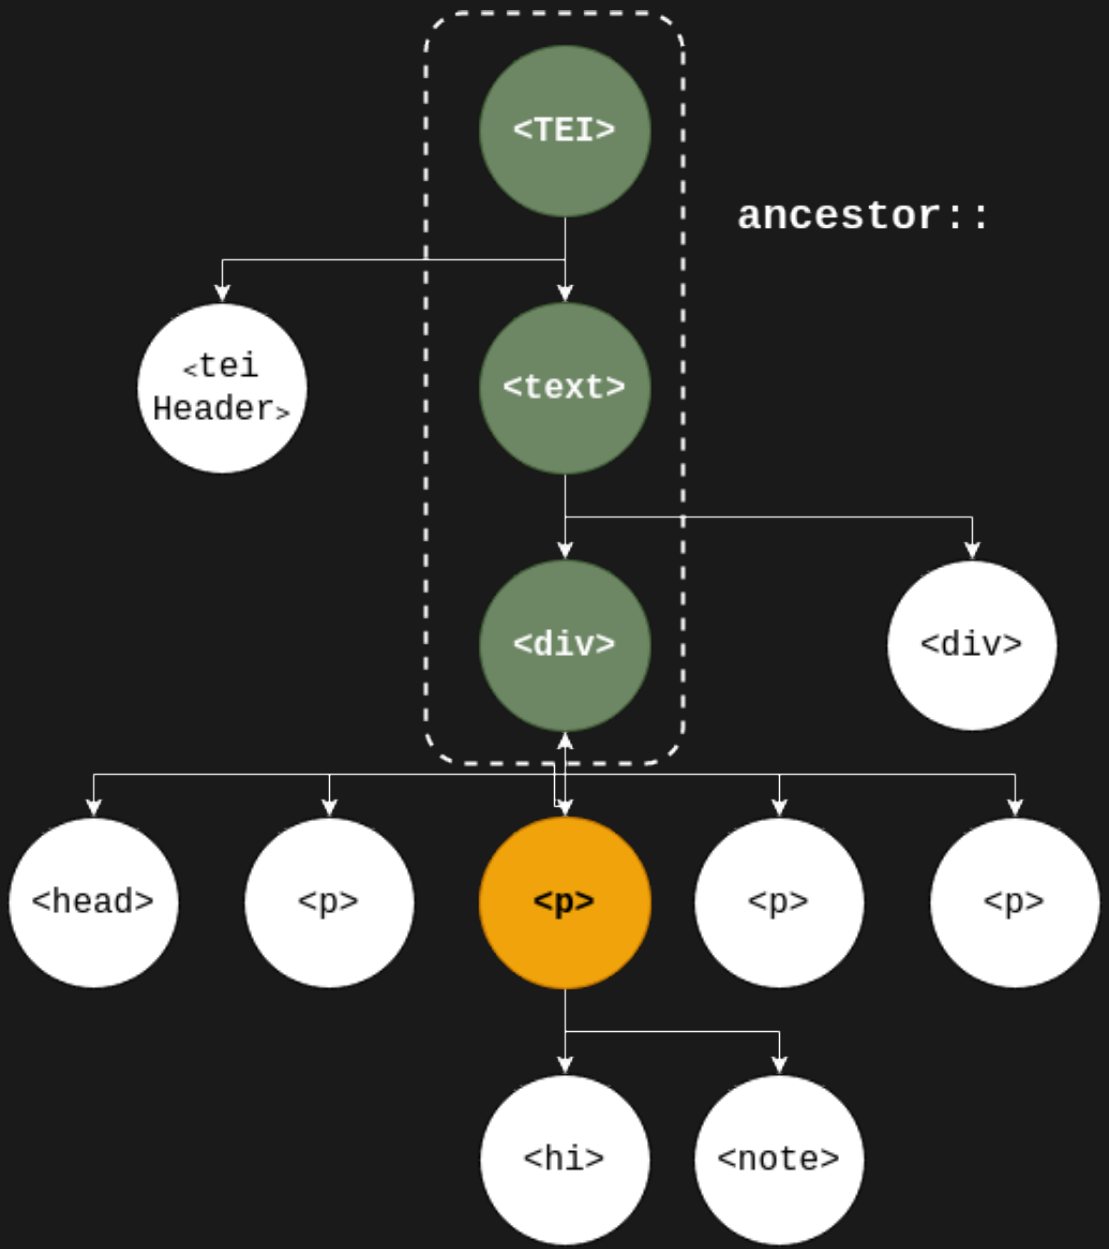

XPath/ Axe `child::`

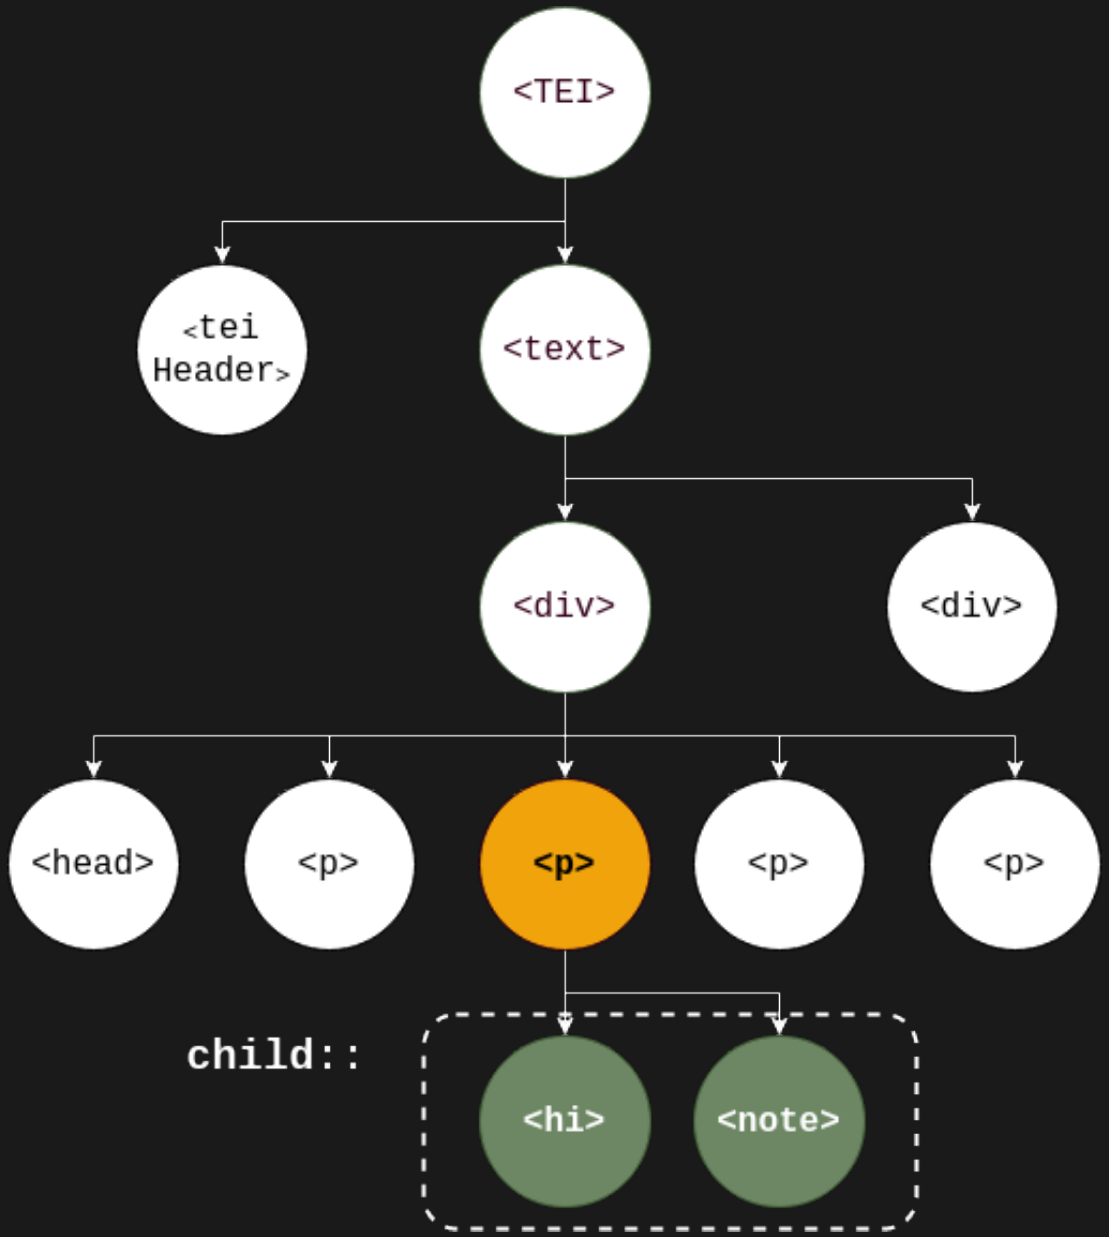

XPath/ Axe following-sibling::

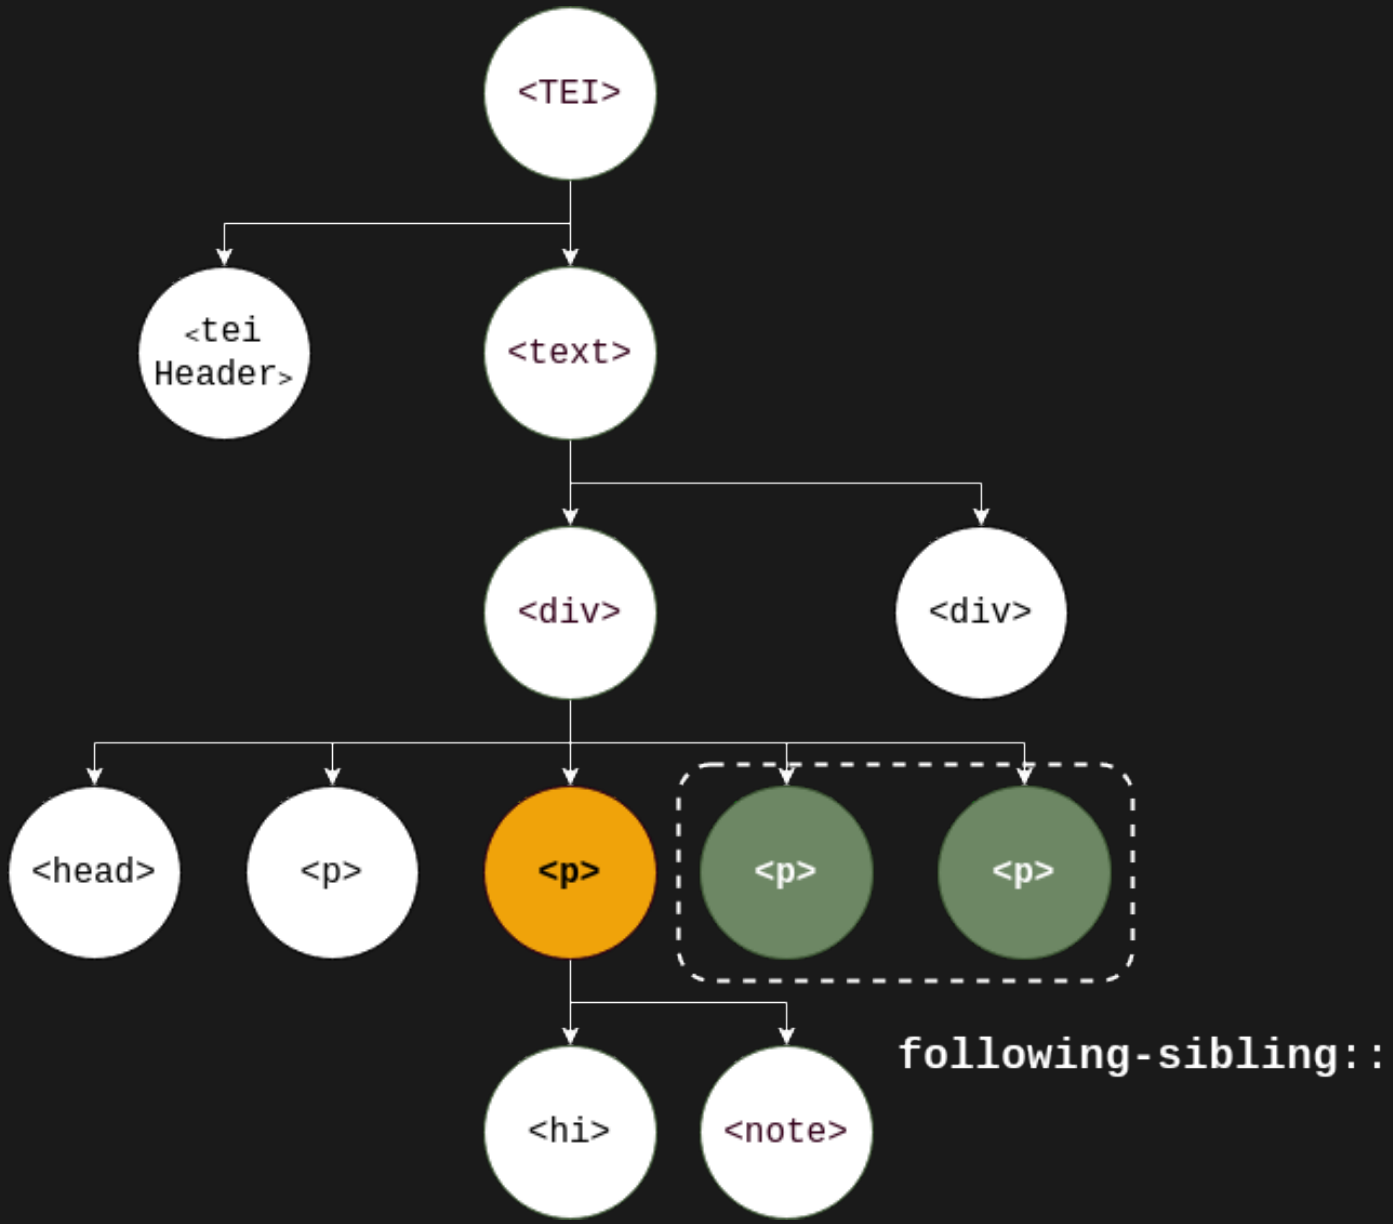

XPath/ Exercice n°2. *Saint Julien l'hospitalier*, II.

- Donner le chemin le plus court de la racine au titre du chapitre.

Prédicats : définition

- Prédicat (filtre) = **condition** qui doit être satisfaite par le nœud courant (existence d'un attribut, valeur d'un attribut, position d'une balise, etc.).
- Écrit entre crochets *[ ]*.

- *//div[@n='2']/head* = le *<head>* de la * * avec un *@n* de valeur *2*.

- *//body/div[@n='2']/p[2]* = ?

Prédicats : exemples

- *//tag[position()=1]* ou *//tag[2]* → condition de position (*<tag>* n°2);
- *//tag[last()]* → idem (dernier *<tag>*);
- *//tag[@foo='bar']* → expression logique (*<tag>* avec un *@foo* dont la valeur est *bar*);
- *//tag[@foo='bar' and @baz='qux']* → *<tag>* avec un *@foo* dont la valeur est *bar* et un *@baz* dont la valeur est *qux*.

 Exercice n°3. *Saint Julien l'hospitalier*, II.

- Utiliser un prédicat pour sélectionner les `<title>` ayant pour texte *Trois Comtes*.
- Utiliser un prédicat pour sélectionner le **deuxième** ou le **cinquième paragraphe** du **premier chapitre** (deux solutions).

- Arbre XML, racine, nœuds (7);
- Chemin XPath, opérateur / ;
- Axes de relation (13);
- Prédicats.

XSLT : première approche

XSLT/ Définition

- XSLT → un **langage de programmation déclaratif** ;
- Permet de **transformer un doc XML** en un autre doc (, *.xml*, *.html*, *.tex*, etc.);
- Transformation opérée par un **processeur XSLT**
  - **Lit** et **transforme** le document d'entrée selon les **règles** de la feuille de style XSL ;
  - Le plus connu → **Saxon** (en ligne de commande);
  - Généralement **intégrés** à des logiciels (**Oxygen**) ou des navigateurs.

- Feuille de style XSL == un doc XML *`.xsl`*;
- Contient des instructions ou règles (*templates*);
- Élément racine : *`<xsl:stylesheet>`*

Présents de base dans Oxygen :

- *`@xmlns:xsl`* : espace de nom (*namespace*) XSL ;
- *`@xmlns:xs`* : espace de nom XML ;
- *`@xmlns:tei`* : espace de nom TEI ;
- *`!@exclude-result-prefixes`* : liste des préfixes qui ne seront pas copiés dans l'output (*`xs`*, *à ajouter :* *`tei`*) ;
- *`@version`* : version de XSL (1, 2 ou 3).

À ajouter dans Oxygen :

- *`@xmlns`* : espace de nom de l'élément racine de l'output;
  - évite l'ajout de cet espace de nom sur chaque élément "matché" par une règle (contenu dans le *`@match`* de *`<xsl:template>`*).
- *`@xpath-default-namespace`* : espace de nom des chemins XPath.
  - évite de devoir écrire le préfix *`tei:`* devant chaque nœud d'une expression XPath.

XSLT/ Ordre d'application des règles

- L'ordre d'écriture des règles n'a aucune importance ;
- XSLT lit chaque nœud du doc XML et applique la règle associée ; s'il n'y a pas de règle, il passe au suivant.
- Donc $\rightarrow$ vous avez la possibilité de vous organisez comme vous le souhaitez dans votre feuille de style.

- *<xsl:template>* → définir une règle ;
- Toujours accompagnée d'un *@match* ;
- *@match* a pour valeur un chemin XPath qui donne l'emplacement du nœud sur lequel sera appliquée la règle.

XSLT/ Élément `apply-template`

- *<xsl:apply-template>*