ENC/ XSLT/ Fiche XPath

Jean-Damien Généro

2023

1. Les noeuds

Pour XPath, un document XML est un "tree of nodes" ("arbre avec des noeuds"). Chaque noeud est une "étape" possible dans une expression XPath. Il y a sept types de noeud :

1.1 Root node

- Notation : /.
- Il contient l'ensemble du document ; c'est le seul noeud "orphelin" (il ne peut pas avoir de parent). On parle parfois du document node.
- À ne pas confondre avec l'élément racine (root element) d'un document XML : <TEI> est entièrement contenu dans le root node tout en étant le seul root element du document.

1.2 Element nodes

- Notation : element().
- Les éléments (i. e. balises) du document XML, notés entre < >.

1.3 Attribute Nodes

- Notation: attribute().
- Les attributs sont des balises XML. Le parent direct d'un attribute node est forcément un element node.

1.4 Text nodes

- Notation : text().
- Le texte d'un element node ou d'un attribute node.

1.5 Comment nodes

• Notation : comment().

- Les commentaires d'un document XML (notés entre <!-- -->).
- Le comment node sélectionne le texte du commentaire sans les <!--->.

1.6 Namespace nodes

- Notation : via l'axe namespace : : .
- Les noms de domaine, généralement stockés dans des xmlns:. Cela signifie que dans <TEI xmlns="http://www.tei-c.org/ns/1.0">, xmlns n'est pas un attribute node mais un namespace node. On y accède par l'expression /TEI/namespace::*.
- Très peu utilisés en XSLT.

1.7 Processing instruction nodes

- Notation: processing-instruction().
- Les instructions de traitement XML (notées entre <? ?>) indiquent à une application comment traiter le document XML qu'elle lit.
- Elles possèdent un nom (name()) et une valeur (string()).
- Exemple: <?xml-stylesheet href="exemple.xsl" type="text/xsl" title="Exemple"?>.
- À ne pas confondre avec l'entête XML (<?xml version="1.0" encoding="UTF-8"?> au début du document).

2. Les axes

• Les axes (axis) permettent de s'émanciper de la direction de base parent>enfant d'un chemin XPath ou précisant ou en changeant cette direction.

• Il y a treize axes.

• Ils se notent avec des :: à la fin ; certains peuvent être abrégés.

2.1 Child axis

- Notation : child::.
- Sélection : la balise hiérarchiquement inférieure au noeud de contexte.
- Attention :
 - C'est l'axe par défaut, ce qui signie que /child::TEI/child::teiHeader est identique à /TEI/teiHeader.
 - Les attribute nodes et namespace nodes sont exclus de cet axe.

2.2 Parent axis

- Notation et abréviation : child:: et .. (deux points).
- Sélection : la balise hiérarchiquement supérieure au noeud de contexte.
- Exemples : //fileDesc/parent::teiHeader et //fileDesc/.. sélectionnent le <teiHeader> depuis le <fileDesc>.

2.3 Self axis

- Notation et abréviation : self:: et . (un point).
- Sélection : le noeud de contexte.

2.4 Attribute axis

- Notation et abréviation : attribute:: et @.
- Sélection : les attributs du noeud de contexte.
- Attention : si le noeud de contexte est un *attribute node*, il n'y a pas d'axe attribut.
- Exemples: //titleStmt/title/attribute::level et //titleStmt/title/@level sélectionnent l'attribut level de <title>.

2.5 Ancestor axis

- Notation: ancestor::.
- Sélection : tous les noeuds entre la balise hiérarchiquement supérieure au noeud de contexte (= le parent) et le premier du document (= le root node).
- Exemple: //titleStmt/title/ancestor::fileDesc/sourceDesc//author sélectionne tous les <author> dans <sourceDesc> depuis <title>.

2.6 Ancestor-or-self axis

- Notation: ancestor-or-self::.
- Sélection : le noeud de contexte et ancestor axis.

2.7 Descendant axis

- Notation : descendant::.
- Sélection : tous les enfants du noeud de contexte, et leurs enfants, et ainsi de suite.
- Exemple: //descendant::sourceDesc.
- Attention: les attribute nodes et namespace nodes ne sont pas pris en compte par cet axe.

2.8 Descendant-or-self axis

- Notation : descendant-or-self::.
- Sélection : le noeud de contexte et descendant-axis
- Attention: les attribute nodes et namespace nodes ne sont pas pris en compte par cet axe.

2.9 Preceding-sibling axis

• Notation: preceding-sibling::.

- Sélection : tous les noeuds qui ont le même parent que le noeud de contexte et qui sont avant lui dans l'arbre.
- Exemples: //sourceDesc/preceding-sibling::titleStmt sélectionne le <titleStmt> depuis le <sourceDesc>; //sourceDesc/preceding-sibling::* sélectionne le <titleStmt> et le <publicationStmt>.

2.9 Following-sibling axis

- Notation: following-sibling::.
- Sélection : tous les noeuds qui ont le même parent que le noeud de contexte et qui sont après lui dans l'arbre.
- Exemple : //publicationStmt/following-sibling::sourceDesc sélectionne le <sourceDesc> depuis le <publicationStmt>.

$2.10\ Preceding\ axis$

- Notation: preceding::.
- Sélection : tous les noeuds qui précèdent le noeud de contexte, peu importe leur parent.
- Attention: les ancestor, les attribute et les namespace ne sont pas pris en compte.

2.12 Following axis

- Notation: following::.
- Sélection : tous les noeuds qui suivent le noeud de contexte, peu importe leur parent.
- Attention: les ancestor, les attribute et les namespace ne sont pas pris en compte.

$2.13\ Name space\ axis$

- Notation: namespace::.
- Sélection : les noms de domaine du noeud de contexte.
- Attention: ne fonctionne pas avec un attribute node.

3. Fonctions XPath

XPath possède des fonctions prédéfinies :

- Elles sont reconnaissables par leurs () finales;
- Elles peuvent avoir un ou plusieurs arguments, ou ne pas en avoir du tout ;
- Dans XSLT, elles peuvent être utilisées dans les @match ou les @select ;
- Elles peuvent retourner : une valeur booléenne (true ou false), un nombre, une chaîne de caractères (string) ou une liste de noeuds (nodeset) ;

- Les opérateurs suivants sont utilisables avec les fonctions et prédicats XPath :
 - Opérateurs numériques : +, -, *, div (division), mod (modulo).
 - Opérateurs booléens : <, <=, >, >=, =, !=, and, or.

Sélection de fonctions :

3.1 concat()

• concat(string1, string2, ...) : retourne la concaténation de string1 et string2 (et plus).

3.2 upper-case() et lower-case()

- upper-case(string) : retourne string en haut-de-casse ;
- lower-case(string): retourne string en bas-de-casse.

3.3 translate() et replace()

- translate(string, 'abc', 'ABC'): retourne string avec:
 - a remplacé par A ;
 - b remplacé par B ;
 - c remplacé par c.
 - NB: le troisième paramètre n'a pas besoin d'être de la même taille que le deuxième. Avec translate(string, 'abc', ''), tous les a, les b et les c seront enlevés de string.
 - Ce n'est pas l'équivalent d'un "rechercher/remplacer".
- replace(string, abc, ABC) : retourne string avec abc replacé par ABC.
 - Ce peut être considéré comme l'équivalent d'un "rechercher/remplacer".
 - Attention : ne fonctionne qu'à partir de XSLT version 2.

3.4 contains()

• contains(string1, string2): retourne true ou false selon que string1 contienne (true) ou ne contienne pas string2 (false).

3.5 starts-with() et ends-with()

- starts-with(string1, string2): retourne true ou false selon que string1 commence (true) ou ne commence pas par string2 (false);
- ends-with(string1, string2): retourne true ou false selon que string1 se termine (true) ou ne se termine pas par string2 (false);

3.6 not()

• not(arg) : évalue arg et retourne la valeur opposée.

- \\title[not(@level = 'm')] renvoie tous les <title> dont le
 @level n'a pas pour valeur m ainsi que ceux qui n'ont pas de @n.
- Attention : ce n'est pas l'équivalent de l'opérateur booléen !=. \\title[@level != 'm')] renvoie tous les <title> qui ont un @level dont la valeur n'est pas m.
- Peut être combiné avec contains() sous la forme de not (contains (..., ...)).

3.7 last(), position() et count()

- NB : dans XPath, la numérotation commence à 1.
- last(): évalue la taille d'un ensemble de balises.
 - Exemple d'utilisation : appliquer une règle à la dernière balise d'un ensemble. Ainsi, //div/p[last()] renvoie tous les en dernière position dans les <div>.
- position () : évalue la position d'une balise au sein de l'ensemble de balises auquel s'applique la règle courante.
 - Exemple d'utilisation : atteindre une balise en fonction de son emplacement. Ainsi, //div/p[position() = 5] renvoie tous les en cinquième position dans les <div>.
 - //div/p[position() = 5] et //div/p[5] sont deux expressions identiques.
 - Attention : position() ne permet pas de déterminer la position de la balise par rapport à son parent.
- count(arg) : évalue le nombre de node et retourne ce nombre.
 - Le résultat est identique à last(), la différence étant que count() prend une expression XPath en argument.
 - Exemple d'utilisation : connaître le nombre total d'élément au sein d'un parent (comme le nombre de au sein d'une <div>).